UNIVERSITÉ
DE REIMS
CHAMPAGNE-ARDENNE

Licence Informatique
Université de Reims

INFO0503 – IA

CM2 : Réduction de dimension par Vectorisation en Analyse en Composante Principale

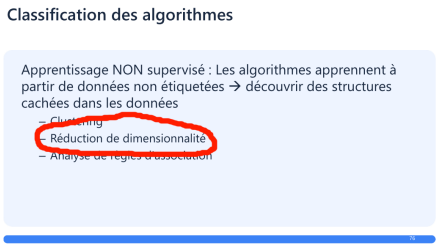


Goéry Valance

LAB-I*

Réduction de dimension

1 Le fléau de la dimension (*curse of dimensionality*)



Ce terme, inventé par Richard Bellman en 1961, se retrouve en intelligence artificielle, et plus particulièrement en apprentissage automatique. Les jeux de données utilisés pour entraîner les modèles comportent en effet souvent un grand nombre de variables descriptives (ou caractéristiques). Or, un nombre excessif de variables d'entrée pose plusieurs problèmes :

- le temps de calcul et l'espace de stockage augmentent de manière significative ;
- les données deviennent éparses dans un espace de grande dimension, ce qui dégrade la capacité des modèles à identifier des schémas explicatifs ;
- la présence de variables redondantes ou non informatives introduit du bruit et nuit à la généralisation du modèle.

Par exemple : 100 observations couvrant l'intervalle unidimensionnel [0,1] permettent de dresser un histogramme et d'en tirer des inférences. En revanche, dans l'espace à 10 dimensions $[0,1]^{10}$, ces mêmes 100 observations ne sont que des points isolés dans un vaste espace vide. Pour obtenir une couverture équivalente, il faudrait pas moins de 10^{20} observations !

Dans le contexte du machine learning, le fléau de la dimension désigne la relation inverse entre l'augmentation des dimensions du modèle et la diminution de la « généralisabilité » : plus le nombre de variables d'entrée augmente, plus l'espace du modèle s'étend et les données deviennent clairsemées.

Ajoutons que des variables très corrélés gênent l'optimisation par descente de gradient (penser la recherche de maximum en MINF0201).

2 La réduction de la dimensionnalité

Une des solutions consiste à remplacer les données originales par des données dans un espace de plus petite dimension, tout en conservant l'essentiel des caractéristiques de celles-ci : c'est la **réduction de la dimensionnalité**.

Pour que l'opération soit utile, il faut bien sûr que ces nouvelles données représentent bien les précédentes. Il y a deux grandes approches :

- **Sélection de caractéristiques** : consiste à préserver un sous-ensemble des variables d'entrée. On élimine les variables superflues et on réduit ainsi le nombre de colonnes de la matrice d'observations. Il s'agit d'un cas particulier de transformation linéaire.
- **Extraction de caractéristiques** : consiste à créer de nouvelles variables en appliquant aux variables d'entrée une transformation (linéaire ou non linéaire). On remplace les variables originales par un nouveau jeu de variables plus petit.

On peut également distinguer les méthodes selon leur objectif : préserver les distances entre les données, approcher des propriétés globales (variance), estimer une variété latente, ou optimiser un critère lié à un problème spécifique (prédiction, approximation de modèle).

3 Méthodes linéaires de réduction de dimension

a) ACP : Analyse en Composantes Principales (PCA en anglais)

L'analyse en composantes principales est peut-être la méthode de réduction de dimensionnalité la plus courante. L'idée est de combiner et transformer les variables quantitatives d'origine du jeu de données pour produire de nouvelles variables quantitatives (ou vecteur) décorrélées entre elles.

Les différentes composantes principales sont choisies successivement pour maximiser la projection du nuage de points sur la composante, tout en étant orthogonales aux composantes précédentes. Le taux de variance expliquée pour chaque composante principale mesure la part d'information conservée.

b) Analyse des correspondances multiples (ACM)

L'analyse des correspondances multiples (ACM) est une méthode d'analyse factorielle adaptée aux données qualitatives (aussi appelées catégorielles). Un exemple typique de données utilisées en ACM est celui des enquêtes d'opinion, les questionnaires étant souvent composés de questions à choix multiples.

Comme une variable quantitative peut être convertie en variable catégorielle, par exemple en regroupant par classe, l'ACM est une méthode générale qui s'applique à tout tableau dans lequel un ensemble d'individus est décrit par des variables de tout type.

Comme toute analyse factorielle, l'ACM peut s'interpréter géométriquement à partir d'un nuage de points dont les points représentent les lignes (individus) ou les colonnes (modalités) du tableau analysé. Si les calculs sont différents, son utilisation est finalement assez similaire à l'ACP : seules les premières composantes sont retenues afin de réduire la dimension tout en conservant l'essentiel de l'information.

4 Méthodes non linéaires

Les méthodes linéaires limitent les possibilités de réduction. Or, de nombreuses structures de données ne sont pas linéaires. Des méthodes non linéaires ont donc été développées pour estimer une variété latente dans les données (par exemple des structures en anneau).

a) t-distributed stochastic neighbor embedding (t-SNE)

L'algorithme t-SNE modélise les similarités entre les paires de points dans chaque dimension par des lois de probabilité. Le « t » désigne la loi de Student utilisée pour modéliser les similarités entre les points en petite dimension. Son utilisation est déliquate.

b) Uniform Manifold Approximation and Projection (UMAP)

UMAP (*Uniform Manifold Approximation and Projection*) est une méthode similaire à t-SNE, mais fondée sur la géométrie riemannienne (l'étude des variétés riemanniennes).

c) Locally Linear Embedding (LLE)

LLE repose sur le principe suivant : localement, le nuage d'observations peut être considéré comme linéaire. Chaque observation est reconstruite comme une moyenne pondérée de ses plus proches voisins. Dans l'espace réduit, on cherche à placer les points de sorte que chaque observation réduite puisse être reconstruite par la même combinaison linéaire de ses voisins réduits. L'objectif est ainsi de conserver la notion de voisinage entre les observations.

d) Analyse en composantes principales à noyau (kernel PCA)

L'ACP à noyau étend l'ACP classique à des structures non linéaires en appliquant une transformation via une fonction noyau (*kernel trick*), ce qui permet de capturer des relations non linéaires entre les variables.

Seule l'ACP « linéaire » sera traitée dans cette partie du cours mais on voit qu'une bonne compréhension de celle-ci est une excellente clé d'entrée vers ces autres méthodes.

5 Sources

- Fléau de la dimension – Wikipédia : https://fr.wikipedia.org/wiki/Fl%C3 %A9au_de_la_dimension
- Réduction de la dimensionnalité – Wikipédia : https://fr.wikipedia.org/wiki/R%C3 %A9duction_de_la_dimensionnalit%C3 %A9
- Qu'est-ce que la réduction de dimensionnalité ? – IBM : https://www.ibm.com/fr-fr/think/topics/dimensionality-reduction
- Réduction non-linéaire de dimension – Cnam : HTTPS://CEDRIC.CNAM.FR/VERTIGO/COURS/ML/COURSREDUCTIONDIMENSION.HTML

Analyse en Composante Principale

1 Principe mathématique sur un exemple :

L'Analyse en Composantes Principales (ACP) s'applique à des tableaux croisant des individus et des variables quantitatives. Selon un usage bien établi, les lignes du tableau représentent les individus et les colonnes représentent les variables. Avec Python et Panda c'est exactement un dataframe de données numériques.

Dans notre exemple on a une 10 variables quantitatives sur des 62 espèces d'animaux :

Espèce	Poids Corporel	Poids Cerveau	Sommeil Total	Espérance DeVie	Gestation	……	Indice Danger
Éléphant d'Afrique	6654	5712	3,3	38,6	3		3
……							……
Renard arctique	3,385	44,5	12,5	14	1		1
Éléphant d'Asie	2547	4603	3,9	69	3		4
Babouin	10,55	179,5	9,8	27	4		4
……							…
Tapir du Brésil	160	169	6,2	30,4	4		4

Comment représenter graphiquement ces données comme un nuage de 62 points dans un espace à 10 dimensions ?

Tout comme une photo est une projection d'un ensemble de points d'un espace en 3D sur un plan en 2D sous le meilleur angle possible, on va chercher la meilleure projection possible de notre nuage de points. Meilleurs est ici dans le sens de la perte minimale d'information.

Imaginons un ballon de rugby : il ne viendrait à l'idée de personne de le photographier « de face », de telle sorte qu'il apparaisse comme un ballon rond. Son axe longitudinal est clairement le premier axe à conserver. De la même manière, on va donc choisir, dans l'espace à 10 dimensions, deux axes orthogonaux passant au mieux dans le nuage de points. Il y aura une perte d'information, c'est certain, mais on pourra mesurer cette perte et connaître la validité de notre représentation.

La distance entre deux individus est calculée comme la distance entre deux points de l'espace (à 10 dimensions). Plus cette distance est petite, plus ces individus se ressemblent.

La liaison entre deux variables est mesurée par le coefficient de corrélation linéaire, noté usuellement r. Il s'agit d'un nombre réel appartenant à [-1 ; 1] (tout comme un cosinus).

- Lorsque r = 1 (angle de 0°), les deux variables sont parfaitement liées (tout comme la taille de l'œil gauche est liée à la taille de l'œil droit).
- Lorsque r = -1 (angle de 180°), les deux variables sont parfaitement liées en sens inverse (tout comme la taille est liée au temps de transmission d'une information, de la patte au cerveau).
- Lorsque r = 0 (angle de 90°), les deux variables sont parfaitement décorrélées (tout comme la taille est indépendante de numéro dans la semaine du jour de naissance).
- Les autres valeurs de r correspondent à des situations intermédiaires.

L'ACP permet d'établir un bilan des ressemblances entre individus et des liaisons entre variables, notamment de mettre en évidence des groupes homogènes d'individus et des groupes de variables corrélées. Notre utilité principale sera de pouvoir résumer l'ensemble des variables par un petit nombre de variables synthétiques, appelées composantes principales.

Note : Évidemment si les variables ne sont pas à la même échelle,kg et cm par exemple, ou même « taille de doigt » et « taille de jambe » il convient de les réduire (division par l'écart-type comme vu en MINF0202).

Calculs Mathématiques

En notant X notre matrice des données avec s le plus petit entre le nombre de colonnes et le nombre de lignes.

Pour faire court, trouver les axes factoriels correspond à maximiser une distance au carré. On les trouve par le calcul des valeurs propres (λ_i) et vecteurs propres (u_i) de la matrice X^TX :

L'espace à s dimensions s ≤ p donnant
la meilleure explication (en termes d'inertie) du nuage original
est défini par
les vecteurs propres de X^TX
associés aux s plus grandes valeurs propres

Cette matrice est, à un facteur 1/n ou 1/(n-1) près, la matrice de variances (sur la diagonale) et de covariances (hors-diagonale) des p variables. Le vecteur donnant les projections ayant la plus grande dispersion est donc le vecteur propre à la plus grande valeur propre de la matrice de variances-covariances de X (https://cours.polymtl.ca/geo/marcotte/glq3402/chapitre3.pdf).

Remarques :

i. On prouve que ces vecteurs propres portant nos axes factoriels sont orthogonaux entre eux.

ii. Les projections sur les vecteur propres unitaires u_i définissent des nouvelles variables combinaisons linéaires des variables originales. Les variances de ces nouvelles variables sont : $\frac{1}{n}\lambda_i$. Ces valeurs propres sont « présentées » dans l'ordre croissant.

iii. On sait que la somme des valeurs propres ($\Sigma\lambda i$) d'une matrice est égale à la trace de la matrice originale et le rapport $\lambda_i/(\Sigma\lambda i)$ indique la proportion de la variance totale prise en charge par le ième vecteur propre.

Des explications plus théoriques sont données dans le livret joint issu du livre de Pages et Escoffier. Pour plus de précision mathématiques on ira voir : https://cours.polymtl.ca/geo/marcotte/glq3402/chapitre3.pdf

ACP par l'exemple « Mammifères »

Note : ce code n'est pas destiné à servir d'exemple, seulement à montrer « comment ça marche ».
Il n'est donc pas factorisé ni optimisé, seulement réfléchi pour faire apparaître au mieux les concepts exposés.
Le code est joint dans les pages annexes et voici les sorties textes et graphiques de l'exécution.

Sorties textes :

```
10 variables sur 62 espèces de mammifères.

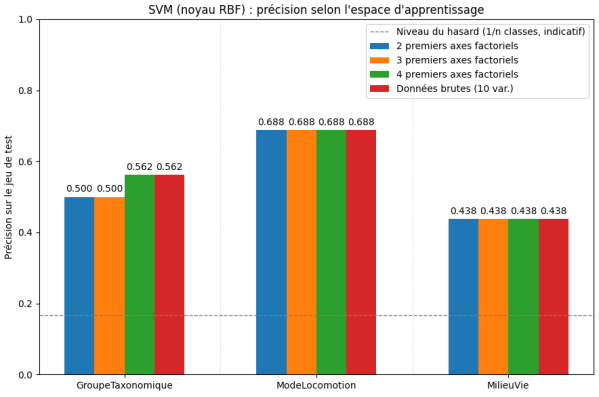
Variance expliquée par axe :
Axe 1 : valeur propre = 4.880 | part = 48.02 % | cumul = 0.00 %
Axe 2 : valeur propre = 2.244 | part = 22.08 % | cumul = 48.02 %
Axe 3 : valeur propre = 1.281 | part = 12.61 % | cumul = 70.10 %
Axe 4 : valeur propre = 0.659 | part = 6.49 % | cumul = 82.70 %
…
Axe 9 : valeur propre = 0.051 | part = 0.50 % | cumul = 99.26 %
Axe 10 : valeur propre = 0.025 | part = 0.24 % | cumul = 99.76 %

Coordonnées des mammifères dans le nouveau repère :
                        Axe 1 Axe 2 Axe 3 Axe 4 Axe 5 Axe 6 Axe 7 Axe 8 Axe 9 Axe 10
Éléphant d'Afrique : +6.5053 +6.7331 +3.4398 -2.0546 -1.3812 +0.0600 +0.6618 +0.3138 -0.3761 -0.3071
Éléphant d'Asie    : +6.1936 +4.1741 +0.3620 +0.0073 +0.8676 +0.5000 -0.4349 -0.6494 +0.7791 +0.6619
…
Chat : -1.9654 +1.2392 -0.2228 +0.6428 +0.6838 -0.2389 +0.4661 +0.0427 -0.0567 -0.0843
Chimpanzé : -0.1336 +1.6746 -1.8584 +0.8491 -0.2874 +0.3271 -0.4244 +0.2120 -0.0513 -0.0815
Homme : +1.2028 +3.0601 -2.9304 +2.1114 +0.8263 +1.8046 -0.2269 +0.1980 +0.0039 -0.0101
…
Souris : -1.1640 -1.0236 +0.8675 -0.1655 -1.0752 +0.6866 -0.1990 +0.0897 +0.0488 +0.1048
Musaraigne asiatique : -1.1650 -0.9366 +0.8794 -0.4363 -0.4939 +0.6323 -0.2980 +0.0713 +0.0364 +0.0560

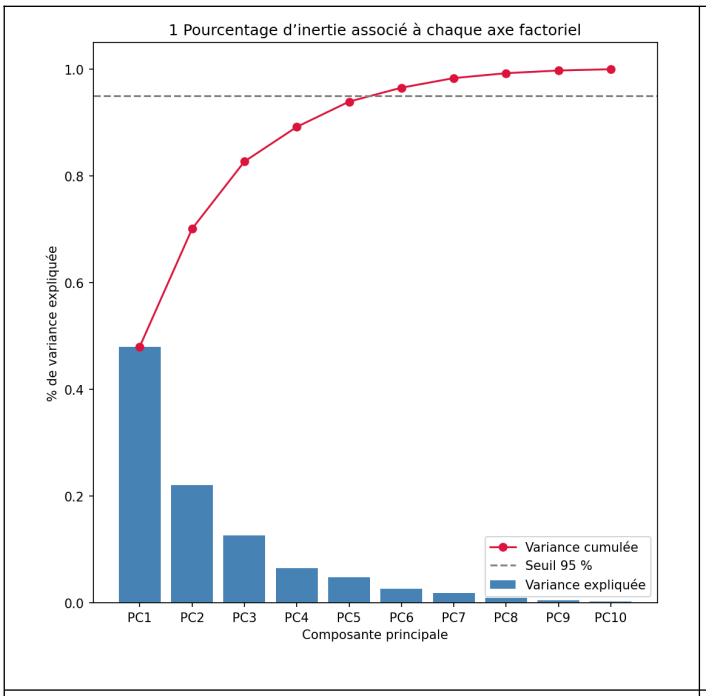
=== Vecteurs propres (coordonnées par variable) ===
                        PC1 PC2 PC3 PC4 PC5 PC6 PC7 PC8 PC9 PC10
PoidsCorporel           0.251 0.442 0.340 -0.333 -0.227 0.071 0.266 0.037 -0.274 -0.559
PoidsCerveau            0.283 0.475 0.226 -0.156 -0.064 0.238 0.048 -0.197 0.363 0.621
SommeilLent             -0.321 0.098 0.456 0.436 -0.376 -0.036 0.058 0.564 0.011 0.158
SommeilParadoxal        -0.291 0.237 0.313 -0.109 0.841 -0.001 -0.039 0.198 -0.007 -0.032
SommeilTotal -0.385 0.091 0.327 0.344 -0.072 0.015 -0.103 -0.748 0.055 -0.200
EspéranceDeVie 0.248 0.304 -0.345 0.645 0.197 0.469 0.126 0.064 -0.084 -0.158
EspéranceDeVieMax 0.373 0.267 0.055 0.182 0.005 -0.423 -0.749 0.056 -0.067 -0.071
Gestation 0.254 -0.426 0.407 0.002 0.064 0.455 -0.227 -0.063 -0.530 0.203
IndiceExpositionSommeil 0.381 -0.136 0.196 0.299 0.201 -0.557 0.531 -0.151 -0.155 0.171
IndiceDanger 0.331 -0.377 0.307 0.079 0.083 0.142 -0.026 0.101 0.688 -0.369
```

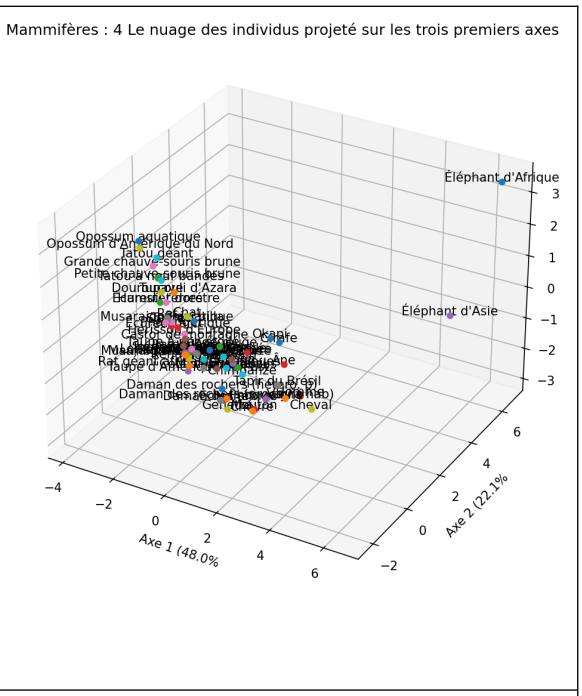
Et ça marche !

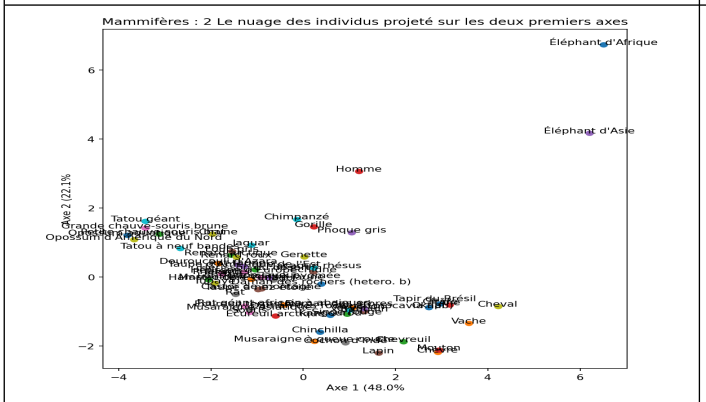
En guise d'exemple on a appliqué une SVM (cours suivant) selon 3 classes différentes en utilisant toutes les dimensions ou seulement les premiers axes factoriel. Alors même que la SVM est peu sensible à la malédiction de la dimension, le gain est tout de même saisissant. Attention notre test est cependant peu fiable du fait du faible nombre de données, ce graphique n'est qu'une illustration pédagogique.

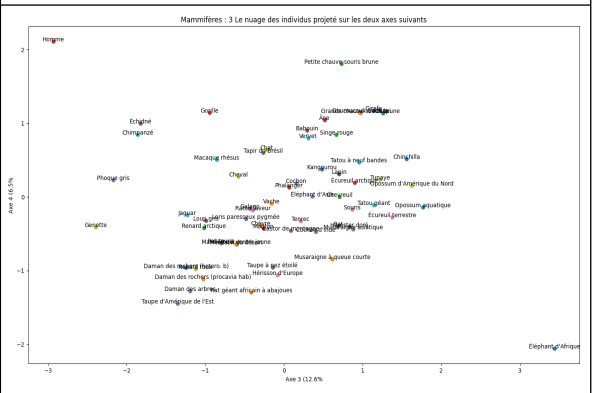


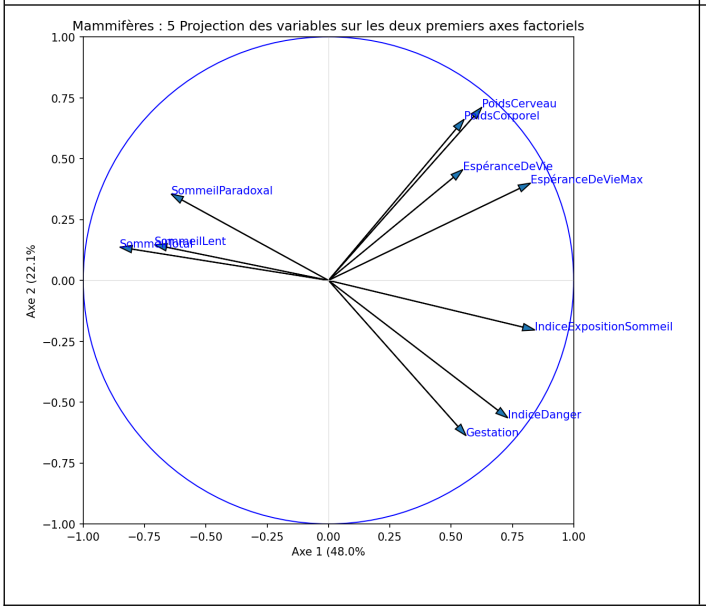
Sorties Graphiques de Mammifere.py

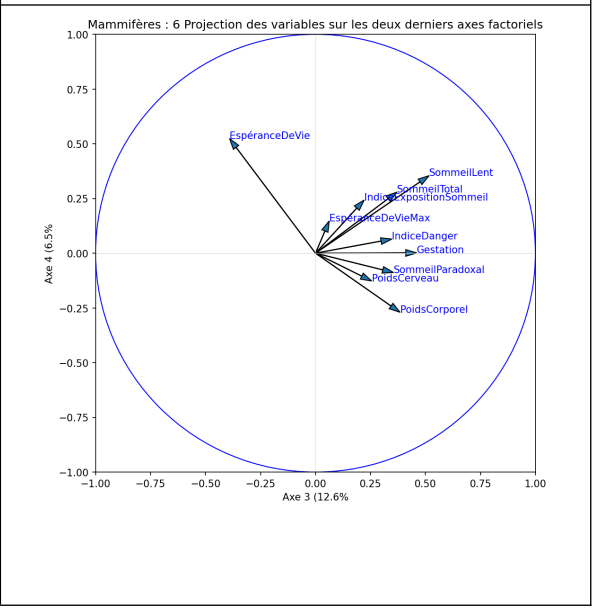












Récapitulatif des méthodes et attributs scikit-learn (mammiferes.py)

1. Le module preprocessing (`preprocessing.scale(X)`)

Centre et réduit chaque colonne du tableau X (elle soustrait la moyenne puis divise par l'écart type). Chaque colonne du tableau résultant est donc de moyenne 0 et d'écart type 1. C'est une étape classique avant une ACP, car l'ACP est sensible aux échelles des variables (une variable exprimée en grammes écraserait une variable exprimée en kilogramme). Ici il a été appelé avec comme paramètre df.to_numpy(), nos données converties en un tableau numpy.

2. Le constructeur PCA avec (`PCA()`)

Crée un objet d'analyse en composantes principales. Par défaut il est calculé autant de composantes que de variables. En pratique on limitera ce nombre ainsi :

- `PCA(n_components=2)` : pour limiter le calcul à 2 composantes principales.
- `PCA(n_components=0.95)` : pour conserver seulement le nombre de composantes suffisant pour expliquer 95 % de la variance.

3. Les méthodes de l'objet PCA (`monACP`)

`monACP.fit(mammiferesCR)`

Méthode d'« entraînement » : cette méthode effectue effectivement tous les calculs de l'ACP. Elle ne renvoie rien d'explicite mais ses résultats sont les attributs de l'objet `monACP`, détaillés ci-dessous.

`monACP.transform(X)`

Méthode qui projette les individus dans le nouveau repère définie par les vecteurs propres calculés lors du `fit`. Elle renvoie un tableau NumPy de même forme que les données d'entrée, où la colonne k contient les coordonnées des individus sur le k-ième axe factoriel. Dans le code, le résultat est stocké dans `mammiferesDansNouveauRepere`.

Remarque : il existe aussi une méthode `fit_transform(X)` qui enchaîne les deux opérations en un seul appel.

4. Les attributs de l'objet PCA (`monACP`)

Tous ces attributs ont été remplis par `monACP.fit(X)`.

`monACP.explained_variance_`

Tableau des valeurs propres de l'ACP, c'est-à-dire **la variance des données portée par chaque axe factoriel**, classées par ordre décroissant.

`monACP.explained_variance_ratio_`

Tableau des proportions de variance expliquée par chaque axe : chaque valeur propre divisée par la variance totale. On l'affiche en pourcentage (par exemple 0,62 signifie que l'axe porte 62 % de l'inertie du nuage).

`monACP.components_`

Tableau des vecteurs propres, appelés composantes principales. La ligne k donc composée des coordonnées du vecteur directeur du k-ième axe factoriel, exprimé dans le repère initial. Dans le code, on le transpose (`.T`) et on le multiplie par la racine carrée des valeurs propres pour obtenir des coordonnées à l'intérieur du cercle des corrélations.

Source :

- Escoffier et Pages, analyse factorielle [Dunod]
- Marcotte (pour l'aspect mathématique) : https://cours.polymtl.ca/geo/marcotte/glq3402/chapitre3.pdf