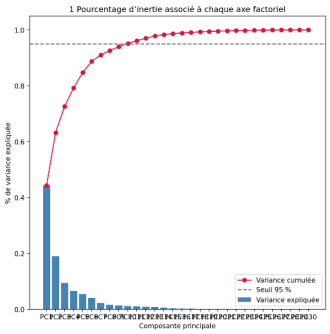
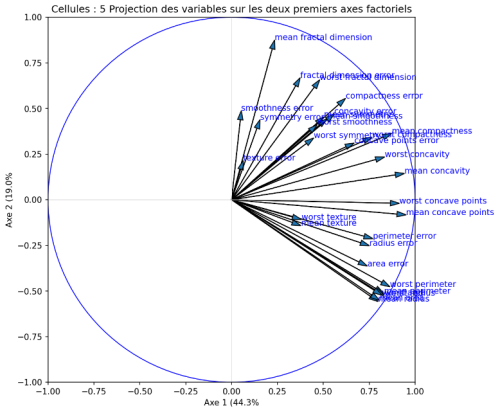
TD Analyse en Composante Principale

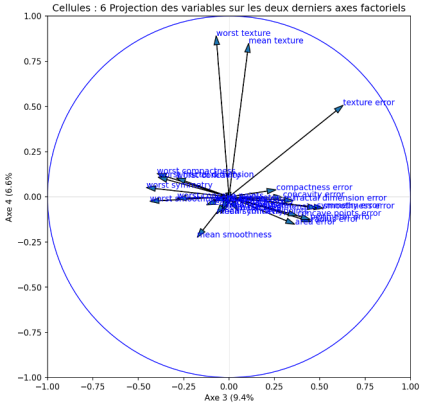
Exercice 1: Premier Exemple

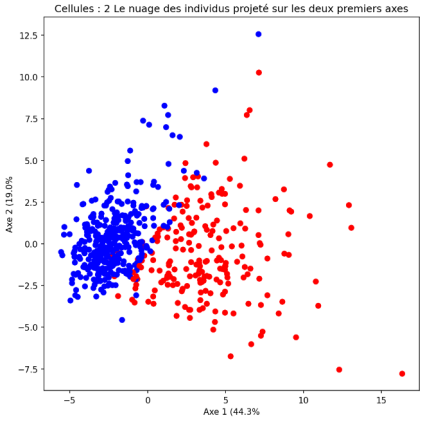
On a repris le script « mammiferes » pour l'appliquer à tableau de données (from sklearn.datasets import load_breast_cancer) sur des cellules plus ou moins malignes.

Sans jamais essayer de comprendre la moindre notion de biologie, commenter les graphiques obtenus ci-dessous en ajoutant des conseils à destination des biologistes.









Exercice 2: Reconnaissance de caractères

Nous allons essayer de faire une préparer une reconnaissance de caractères (1797 images de chiffres en résolution 8×8) mais on pourra répondre également en pensant à un jeu plus grand.

Identifier les difficultés possibles d'une reconnaissance de caractères par un réseau de neurones.

En quoi l'ACP pourrait-être utile ?

Faut-il Centrer/Réduire

Proposer un script dans ses grandes lignes sans s'arrêter aux aspects techniques.

On pourra discuter de la pertinence des calculs et graphiques déjà vus et proposer des graphiques permettant de voir de visu l'efficacité, ou non, de l'ACP sur notre problème.

Exercice 3: Exemple théorique

Afin de mieux voir le fonctionnement de l'ACP, on prend l'exemple théorique suivant créé sur une feuille tableur.

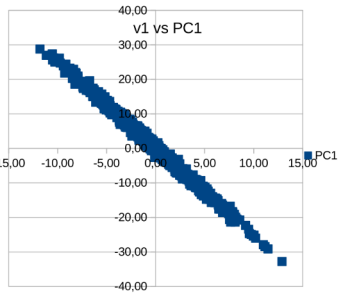
Cet exemple est complètement artificiel :

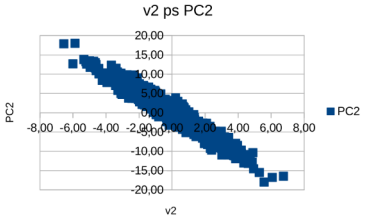
- Les variables v1,v2,v3 sont des variables « cachées » générées suivant une loi aléatoire.
- Les variables X,Y,Z,T sont calculées à partir de v1,v2,v3. A noter que les valeurs de v1 étant deux fois plus importantes en moyenne que celles de v2 (et de même pour v3), v1 prends donc plus d'importance que v2 (et v3) dans les valeurs de X,Y,Z,T sur lesquelles porte notre ACP.
- PC1,PC2 et PC3 sont les composantes principales que l'on calcule par ACP. On y reviendra en fin d'exercice.

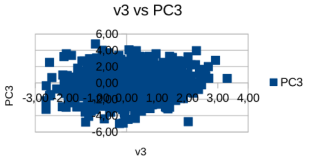
L'idée de cet exercice est de retrouver cette construction à partir des seules valeurs de X,Y,Z,T (sans connaissance même de l'existence de v1,v2 et v3). Quelque chose d'impossible à la seule vue, sans calculs, des valeurs de X,Y,Z, et T.

VecteurMaths

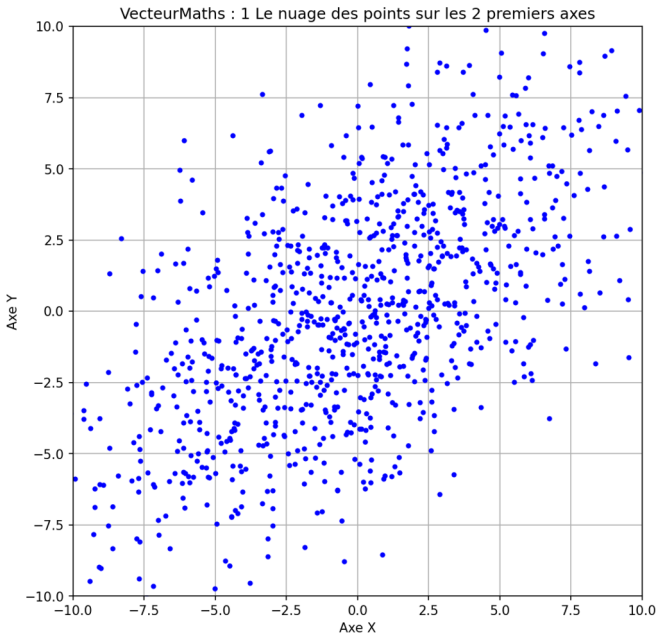
	=LOI.NORMALE.INVERSE(ALEA();0;4)	=LOI.NORMALE.INVERSE(ALEA();0;2)	=LOI.NORMALE.INVERSE(ALEA();0;1)	=$B3+$C3-$D3	=$B3-$C3-$D3	=$B3+2*$C3+$D3	=2*$B3-$C3+$D3	=-0,537*E3-0,479*F3-0,447*G3-0,532*H3	=-0,315*E3+0,584*F3-0,662*G3+0,348*H3	=0,454*E3-0,582*F3-0,482*G3+0,472*H3
	v1	v2	v3	X	Y	Z	T	PC1	PC2	PC3
P001	-3,59	2,53	1,15	-2,21	-7,26	2,61	-8,56	8,05	-8,26	-2,08
P002	-0,18	0,69	0,42	0,09	-1,30	1,63	-0,64	0,18	-2,08	-0,29
P003	-0,24	-3,65	1,13	-5,02	2,28	-6,41	4,29	2,19	8,65	1,51
P004	-6,42	-0,84	-0,93	-6,33	-4,65	-9,04	-12,94	16,55	0,77	-1,92
P005	1,83	1,40	-0,14	3,38	0,57	4,50	2,13	-5,23	-2,97	0,04
P006	-4,39	-0,25	-0,43	-4,22	-3,72	-5,31	-8,97	11,19	-0,45	-1,42
P007	-1,97	-0,02	-0,12	-1,87	-1,83	-2,14	-4,05	4,99	-0,47	-0,67
P008	1,65	2,33	1,28	2,70	-1,96	7,60	2,26	-5,11	-6,24	-0,23
P009	-2,93	-2,35	0,41	-5,70	-1,00	-7,22	-3,10	8,41	4,91	0,01
P010	-0,29	1,59	-0,40	1,70	-1,48	2,49	-2,56	0,05	-3,94	-0,78
P011	3,92	1,18	-1,42	6,51	4,16	4,85	5,24	-10,45	-1,01	0,67
P012	-3,60	3,89	-0,86	1,14	-6,63	3,31	-11,95	7,44	-10,59	-2,86
P013	-5,61	-0,20	0,23	-6,04	-5,65	-5,78	-10,80	14,28	-1,33	-1,77
P014	-10,52	2,32	0,05	-8,25	-12,89	-5,84	-23,32	25,62	-9,18	-4,44
P015	-7,41	0,35	0,96	-8,02	-8,71	-5,76	-14,20	18,61	-3,69	-2,50
P016	5,17	-0,61	2,27	2,30	3,52	6,21	13,22	-12,73	1,82	2,24
P017	-3,19	3,02	-0,24	0,07	-5,97	2,61	-9,63	6,77	-8,59	-2,30
P018	0,19	-1,11	1,39	-2,31	-0,09	-0,64	2,87	0,05	2,09	0,67
P019	5,63	-0,15	-0,45	5,93	6,23	4,87	10,97	-14,18	2,36	1,89
P020	2,39	-3,18	-0,42	-0,37	5,98	-4,39	7,53	-4,71	9,14	2,02
P021	0,33	-3,84	1,13	-4,63	3,04	-6,22	5,63	0,82	9,31	1,78
P022	5,50	0,39	2,69	3,21	2,42	8,97	13,29	-13,96	-0,91	2,00
P023	0,35	2,04	0,07	2,32	-1,76	4,50	-1,28	-1,73	-5,18	-0,69
P024	1,77	0,43	-0,82	3,02	2,16	1,81	2,28	-4,68	-0,09	0,32
P025	1,67	0,10	-0,58	2,35	2,16	1,27	2,66	-4,28	0,60	0,45
P026	-0,55	1,13	0,44	0,14	-2,12	2,14	-1,80	0,94	-3,33	-0,59
P027	7,86	-3,68	-0,80	4,98	12,34	-0,31	18,59	-18,34	12,31	4,00
P028	3,45	1,49	0,44	4,50	1,51	6,87	5,84	-9,32	-3,05	0,61
P029	-10,63	-0,57	-1,34	-9,86	-8,72	-13,10	-22,02	27,04	-0,98	-3,48
P030	-1,04	4,63	0,66	2,93	-6,34	8,89	-6,05	0,71	-12,62	-2,12
P031	-3,29	-0,58	0,47	-4,35	-3,18	-4,00	-5,54	8,59	0,23	-0,81
P032	4,89	-2,04	1,75	1,10	5,17	2,56	13,57	-11,43	5,70	2,65
P033	-1,89	1,20	-0,15	-0,53	-2,94	0,36	-5,13	4,26	-3,57	-1,13
P034	4,51	-0,19	-1,02	5,34	5,73	3,10	8,20	-11,36	2,46	1,47
P035	-2,45	3,35	0,92	-0,03	-6,72	5,17	-7,33	4,83	-9,89	-2,05
P036	-0,73	-0,49	1,52	-2,75	-1,77	-0,20	0,55	2,12	0,16	0,13
P037	-0,27	-3,31	1,64	-5,22	1,40	-5,25	4,42	2,13	7,48	1,43
P038	4,04	2,26	-0,05	6,35	1,82	8,51	5,76	-11,15	-4,56	0,44
P039	-1,55	-0,12	-2,30	0,63	0,87	-4,08	-5,27	3,87	1,17	-0,74
P040	0,08	-1,09	0,34	-1,35	0,83	-1,77	1,58	0,27	2,63	0,50
P041	-3,86	-1,79	0,04	-5,69	-2,11	-7,40	-5,88	10,50	3,42	-0,57
P042	-8,77	-2,63	0,53	-11,93	-6,67	-13,50	-14,39	23,29	3,79	-1,82
P043	-4,01	-0,63	1,06	-5,70	-4,44	-4,21	-6,33	10,44	-0,21	-0,96

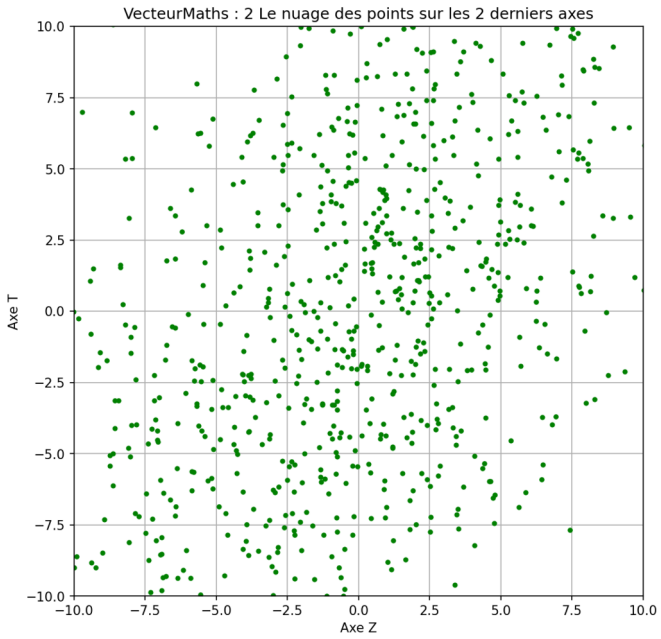


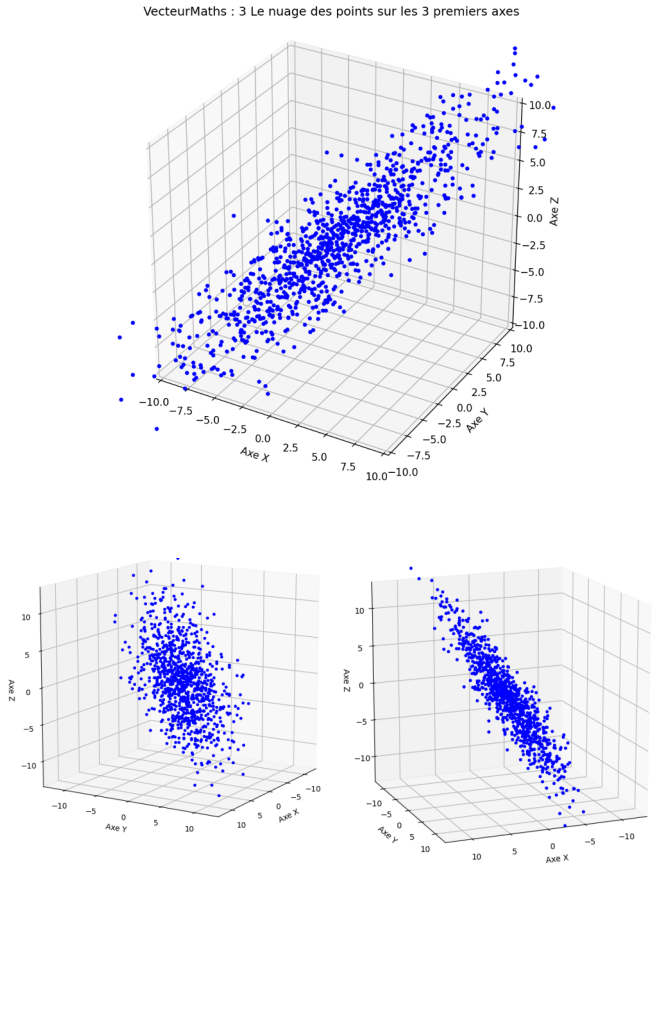


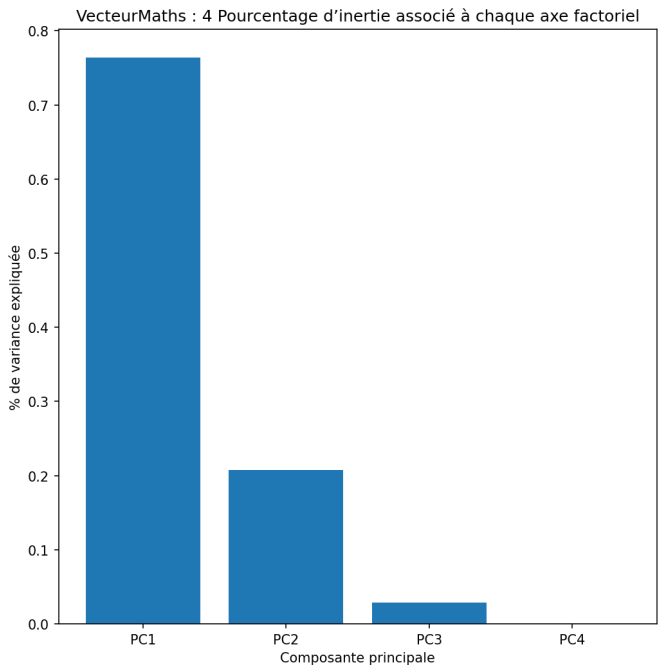


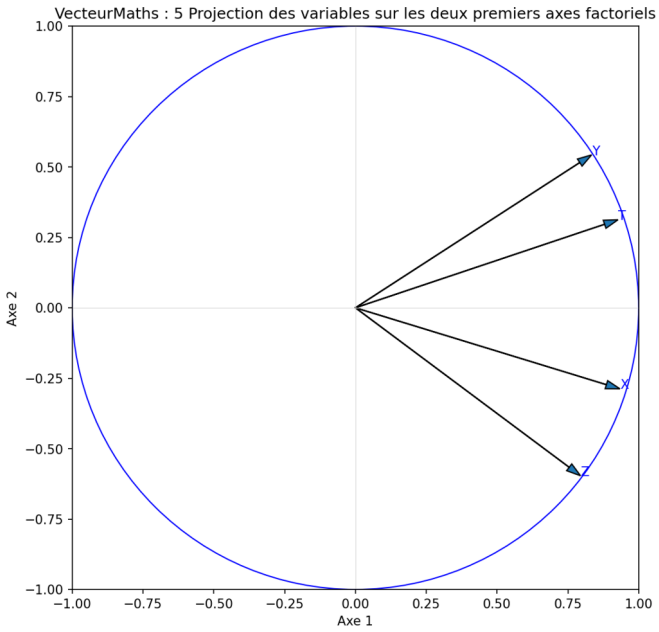
Directement sur la feuille, commenter les graphiques en veillant à expliquer les résultats présentés par ceux-ci à partir de la manière dont X,Y,Z et T ont été calculées.

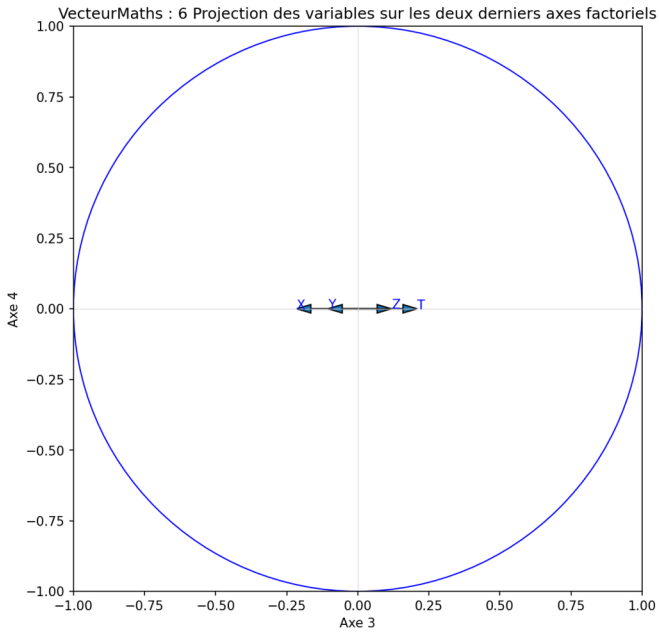

VecteurMaths : 1 Le nuage des points sur les 2 premiers axes
Axe Y
Axe X

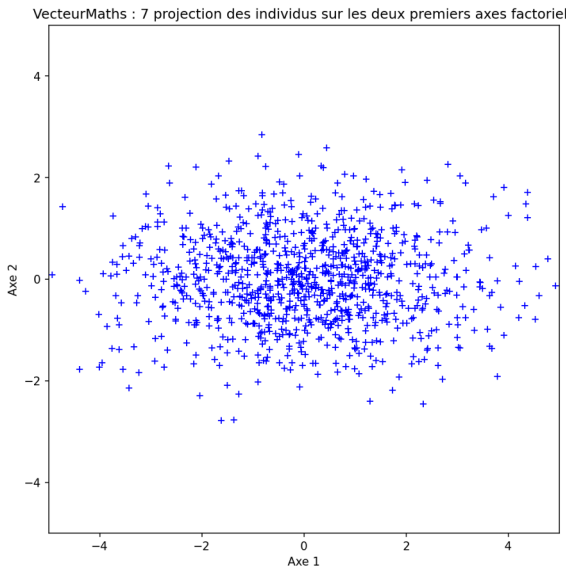

VecteurMaths : 2 Le nuage des points sur les 2 derniers axes
Axe T
Axe Z

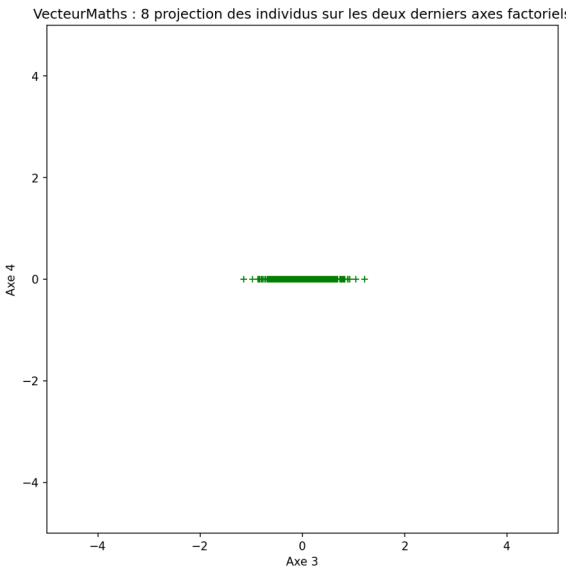

VecteurMaths : 3 Le nuage des points sur les 3 premiers axes
Axe X
Axe Y
Axe Z

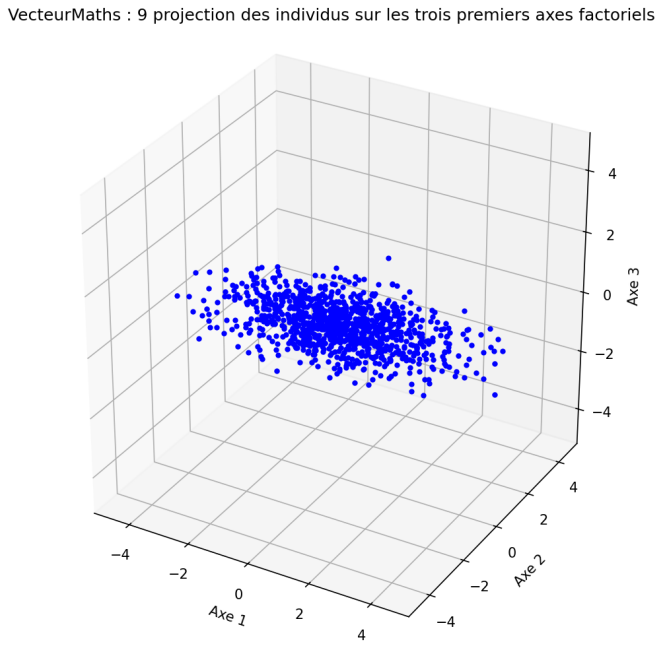

VecteurMaths : 4 Pourcentage d'inertie associé à chaque axe factoriel
% de variance expliquée
PC1
PC2
PC3
PC4
Composante principale

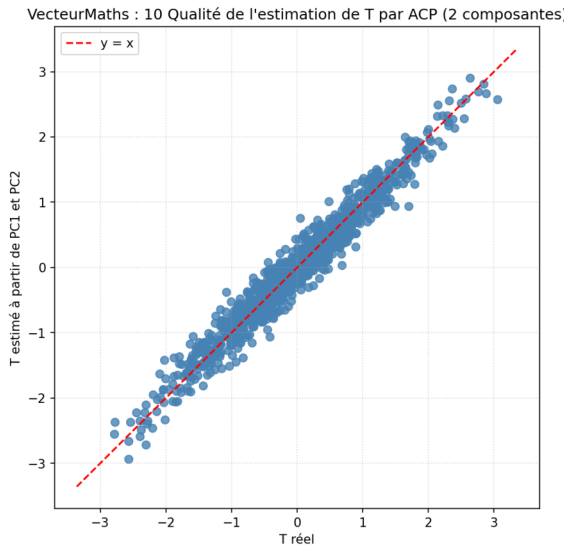

VecteurMaths : 5 Projection des variables sur les deux premiers axes factoriels
Axe 1
Axe 2
Y
T
X
Z


VecteurMaths : 6 Projection des variables sur les deux derniers axes factoriels
Axe 3
Axe 4
X
Y
Z
T


VecteurMaths : 7 projection des individus sur les deux premiers axes factoriels
Axe 1
Axe 2


VecteurMaths : 8 projection des individus sur les deux derniers axes factoriels
Axe 3
Axe 4


VecteurMaths : 9 projection des individus sur les trois premiers axes factoriels
Axe 1
Axe 2
Axe 3


VecteurMaths : 10 Qualité de l'estimation de T par ACP (2 composantes)
y = x
T réel
T estimé à partir de PC1 et PC2

Proposition de correction

Exercice 1:

Le jeu de données comporte 569 individus, des cellules décrites par 30 variables numériques continues (rayon, texture, périmètre, aire, régularité, concavité, etc.).

Une ACP sera certainement utile pour mieux comprendre les corrélations entre variables et peut-être limiter leur nombre.

Les variables étant hétérogènes par leurs unités et leurs ordres de grandeur, les variables doivent être centrées réduite pour l'ACP.

Inertie associé aux axes

La variance expliquée de chaque axe décroît très rapidement : un faible nombre d'axe portera donc déjà beaucoup d'information. Les deux premiers axes portant à eux deux déjà 60 % de l'information, cela valide une représentation 2D.

Avec quatre axe on portera 80 % d'information ce qui peut déjà apporter des applications utiles. Les 10 premiers axes (95%) devraient suffire à résumer nos 30 variables qui semblent donc très redondantes.

Graphique 3 : cercle des corrélations sur le plan factoriel 1-2

Les 30 variables sont projetées sous forme de vecteurs dans le cercle des corrélations.

L'axe1 semble correspondre « aux points concaves » et l'axe 2 à un mixte comprenant la dimension fractale

Comme le vecteur « dimension fractale » semble près du cercle il comme les informations de périmètre : ils semblent bien expliqués par nos deux axes mais aussi peuvent donc servir d'axes. Et comme ils sont presque orthogonaux ont pourrait suggérer aux biologistes de s'intéresser particulièrement à ces deux paramètres s'ils sont faciles à mesurer. On voit que les autres mesures de périmètre peuvent tout à fait être utilisés mais cela est moins le cas pour la dimension fractal qui est la seule utilisable comme seconde dimension.

On voit que les variables du type textures sont courtes et donc cette information sera très mal portée par nos deux premiers axes et notre représentation 2D.

Graphique 4 : projection des variables

Comme attendu, les textures sont bien représentées par un troisième axe, ici l'axe 4 mais l'axe factoriel 3 est vraiment un mélange de tout type d'information (les flèches opposés montrent une corrélation négative : plus de symétrie entraîne moins de « errors ».

Conclusion et proposition

S'il n'y avait que trois variables à retenir pour un biologiste nous citerions les « concaves », « fractal dimension » et « texture ».

Il serait intéressant de refaire l'ACP en retirant les variables beaucoup trop redondantes (flèches touchant le cercle et presques superposées).

Du fait que le quatrième axe soit si concret, toute réduction de dimension devrait comporter au minimum quatre axes.

Exercice 2:

En quoi l'ACP pourrait-elle être utile ?

Diminution de la dimension, décorrélation des axes, suppression du bruit et diagnostic préalable.

Proposer un script dans ses grandes lignes, sans s'arrêter aux aspects techniques.

- Charger les chiffres manuscrits (X) sous forme de tableau. Si on a leurs étiquettes on peut les charger aussi pour « colorer nos points ».
- Les données sont centrées systématiquement pas une ACP. La réduction ne se justifie pas puisque les données sont sur une même échelle et que des points sont plus importants que d'autres (penser aux pixels de coin).
- Ajuster l'ACP ; noter le nombre d'axes pour cumuler 90 % de la variance. Si on souhaite faire une reconnaissance de caractères, on pourrait faire des tests limités avec différents seuil de variance pour trouver le nombre d'axe idéal.
- Projeter sur 2D « pour voir » mais sans illusions:2 axes ne suffisent pas à résumer le dessin d'un caractère.
- Afficher les axes d'une manière lisible : sous forme de caractères
- Afficher quelques caractères calculés seulement à partir de leurs composantes principales pour voir de visu la qualité de notre réduction de dimension.

Exercice 3: ACP sur valeurs calculées

Rappel préalable de la construction des données : les quatre variables observées sont des combinaisons linéaires de trois variables cachées, soit X ≈ v1 − v2 − v3, Y ≈ v1 − v2 − v3, Z ≈ v1 + 2·v2 − v3 et T ≈ 2·v1 − v2 − v3, v1 étant générée avec une amplitude double de celle de v2 et v3, v1 a donc une importance primordiale dans la détermination des valeurs de X,Y,Z et T.

C'est cette structure cachée que l'analyse factorielle doit nous révéler à partir de la seule étude des valeurs de X,Y,Z et T.

VecteurMaths 1 : nuage des points sur les deux premiers axes (X, Y)

Le nuage de points croisant les variables X et Y est nettement allongé selon une direction préférentielle : les points s'étirent le long d'une droite. X et Y semblent fortement corrélés. Effectivement leur formule semble dépendre beaucoup et de la même façon de v1.

VecteurMaths 2 : nuage des points sur les deux derniers axes (Z, T)

Il en est seulement un peu de même entre Z et T. Z dépends à part égale de v1 et v2 alors que T dépends surtout de v2.

VecteurMaths 3 : le nuage des points sur les trois premiers axes factoriels

On retrouve les deux constatations précédentes : deux directions privilégiées et une troisième dimension plus aléatoires : c'est ce que devrait détecter l'analyse factorielle.

VecteurMaths 4 : pourcentage d'inertie associé à chaque axe factoriel

Ce diagramme en barres est l'outil de décision central de l'ACP. On voit toute l'importance du premier axe factoriel et même que l'information est « portée à 0,75+0,20=95%) par les deux premiers axes.

Le fait que les **trois** premiers axes portent l'intégralité de l'information est normal dans notre exemple : X, Y, Z et T ont justement été créés comme combinaisons linéaires des **trois** variables v1, v2 et v3.

VecteurMaths 5 : projection des variables sur les deux premières composantes principales

Note : Les formules de notre exemple ont été construites pour que les axes factoriels que nous nommerons PC1 et PC2, correspondent presque parfaitement à v1 et v2. Mais nous faisons comme si nous ne y attendions pas;)

Chaque variable X, Y, Z, T est représentée par un vecteur dont la direction indique avec quels axes factoriels elle est corrélée. La longueur montre la qualité de la représentation. Ici elle est très bonne (presque 1, l'extrémité des vecteurs touche presque le cercle sauf pour T.

On voit que X et T sont principalement corrélés avec l'axe PC1 et que Y et Z le sont avec les axes PC1 **ET** PC2.

X et T sont vers le bas : il s'agit d'une corrélation négative avec PC2. On retrouve les +$C3 et –$C3 des formules tableurs (le sens du signe a peu d'importance, PC2 correspond à -v2 ce qui ne change rien à nos interprétations.

Les angles sont intéressants, on voit que les vecteurs sont orthogonaux et que donc que Y et Z sont pratiquement décorrélées : connaître la valeur de Y d'un individu ne donne aucune information sur sa valeur de Z.

T est un peu plus court : PC1 et PC2 ne suffisent pas pour expliquer complètement ses valeurs.

VecteurMaths 6 : projection des variables sur les deux dernières composantes principales

Ce second cercle des corrélations, tracé dans le plan (PC3, PC4), présente un contraste important. Conformément aux prédictions de la figure 4, l'axe PC3 porte un peu d'information et l'axe PC4 pas du tout.

VecteurMaths 7 : projection des individus sur les deux premiers axes factoriels

Tout ce qui précède nous dit que cette représentation des est une très bonne représentations des informations de X,Y,Z et T alors même qu'elles étaient au départ en 4D. C'est ce que nous avions prévu en créant nos formules et c'est ce que nous avons retrouvé.

VecteurMaths 8 : projection des individus sur les trois premiers axes factoriels

Comme prévu l'axe 3 apporte un peu d'information contrairement à l'axe 4 qui n'apporte rien.

VecteurMaths 9 : projection des individus sur les trois premiers axes factoriels

Ce graphique en trois dimensions projette simultanément les observations sur les axes PC1, PC2 et PC3, c'est-à-dire dans le sous-espace factoriel de dimension trois qui capte la totalité de l'inertie significative. Les axes du repère correspondent aux axes du nuage. On voit combien l'axe 1 est important.

VecteurMaths 10 : qualité de l'estimation de T par ACP (deux composantes)

Par construction, nous espérions que l'analyse factorielle « découvre par elle-même » la variable v1 : ce graphique montre que c'est bien le cas.

Colonnes PC1, PC2 et PC3 de la feuille tableur

L'analyse factorielle nous donnes les coordonnées de PC1, PC2 et PC3 en fonction de X,Y,Z et T. On a donc appliqué ces formules pour trouver les valeurs de ces variables pour chaque individu et comparer une à une ces valeurs à v1,v2 et v3.

On voit que PC1 correspond bien v1, PC2 un peu moins bien à v2 car elle comporte un peu de v3, et PC3 contient un peu tout le reste y compris un peu de bruit : elle ne correspond pas à v3.

Au final la tâche est accomplie, au lieu d'utiliser les 4 colonnes X,Y,Z,T comme données d'entraînement et d'inférence, il suffit d'utiliser les deux colonnes PC1 et PC2 : le nombre de dimension a été divisé par deux sans grande perte d'information : mission accomplie.